


Influência da Diversidade das Faces

Bruno Costa
João Varela

02/08/2019



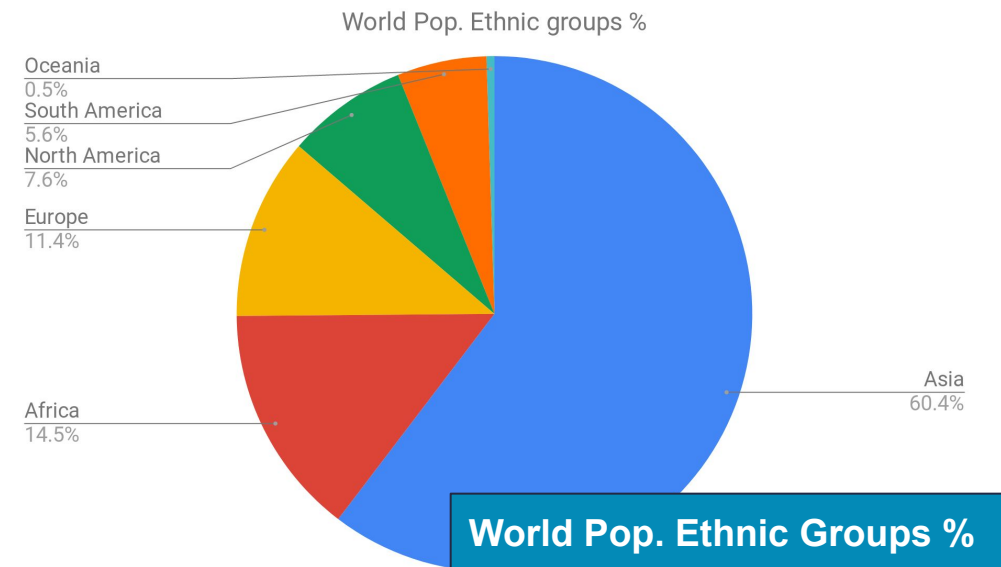

INSTITUTO DE ENGENHARIA
DE SISTEMAS E COMPUTADORES,
TECNOLOGIA E CIÊNCIA



Enquadramento/Objetivos

- Análise das métricas mais relevantes para o reconhecimento facial:
 - *Principal Component Analysis* (PCA)
 - Reduzir a dimensionalidade do problema
- Construir um classificador minimizando os recursos utilizados:
 - *K-means Clustering*
 - Escolher as melhores imagens possíveis para o treino do classificador (as que garantem um dataset com mais variabilidade)
- Comparar o desempenho de classificadores:
 - Segundo o tamanho do dataset de treino
 - Segundo a variabilidade das imagens dentro do dataset de treino

Construção do Dataset



Dataset representativo da população mundial, em termos de etnias e géneros, obtendo assim resultados que nos permitam generalizar para novos casos, de forma mais fiável.

Construção do Dataset


Name		
	Same	Diff
Dalai Lama	462	353
Abdullah_II_of_Jordan	410	391
Aditya_Seal	401	409
Aishwarya_Rai	312	509
Alain_Traoré	312	286
Alex_Gonzaga	299	422
Angélique_Kidjo	423	292
Anne,_Princess_Royal	293	372
Cavaco_Silva	542	359
Aya_Miyama	276	261
Conan_O'Brien	423	427
Zélia_Duncan	491	273

Number of Images per Class

VGGFace2



Análise das métricas mais relevantes



- Através dos pontos faciais foram retiradas 39 métricas (distâncias, áreas, rácios e contrastes).
- O PCA permitiu encontrar as métricas que melhor representam os dois datasets.

Análise das métricas mais relevantes

- Distances
- Areas
- Ratios
- Contrasts




39 Métricas

P
C
A

11 Métricas
(Contraste e
Rácios)

Metrics Weights Per Class

Comparação da Variabilidade dos Datasets



K-fold Cross Validation

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 1	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 2	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 3	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 4	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Split 5	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5


Validation

Training

- Para avaliar a capacidade de generalização do modelo recorreu-se à técnica de validação cruzada, mais especificamente ao método K-fold.
- Treinou-se o classificador usando dois modelos diferentes:
 - Custom Model (5 camadas)
 - Resnet18


Comparação da Accuracy

■ Accuracy (Same) ■ Accuracy (Diff)



Custom Model Accuracy (200 epochs)

■ Accuracy (Same) ■ Accuracy (Diff)



ResNet18 Accuracy (20 epochs)

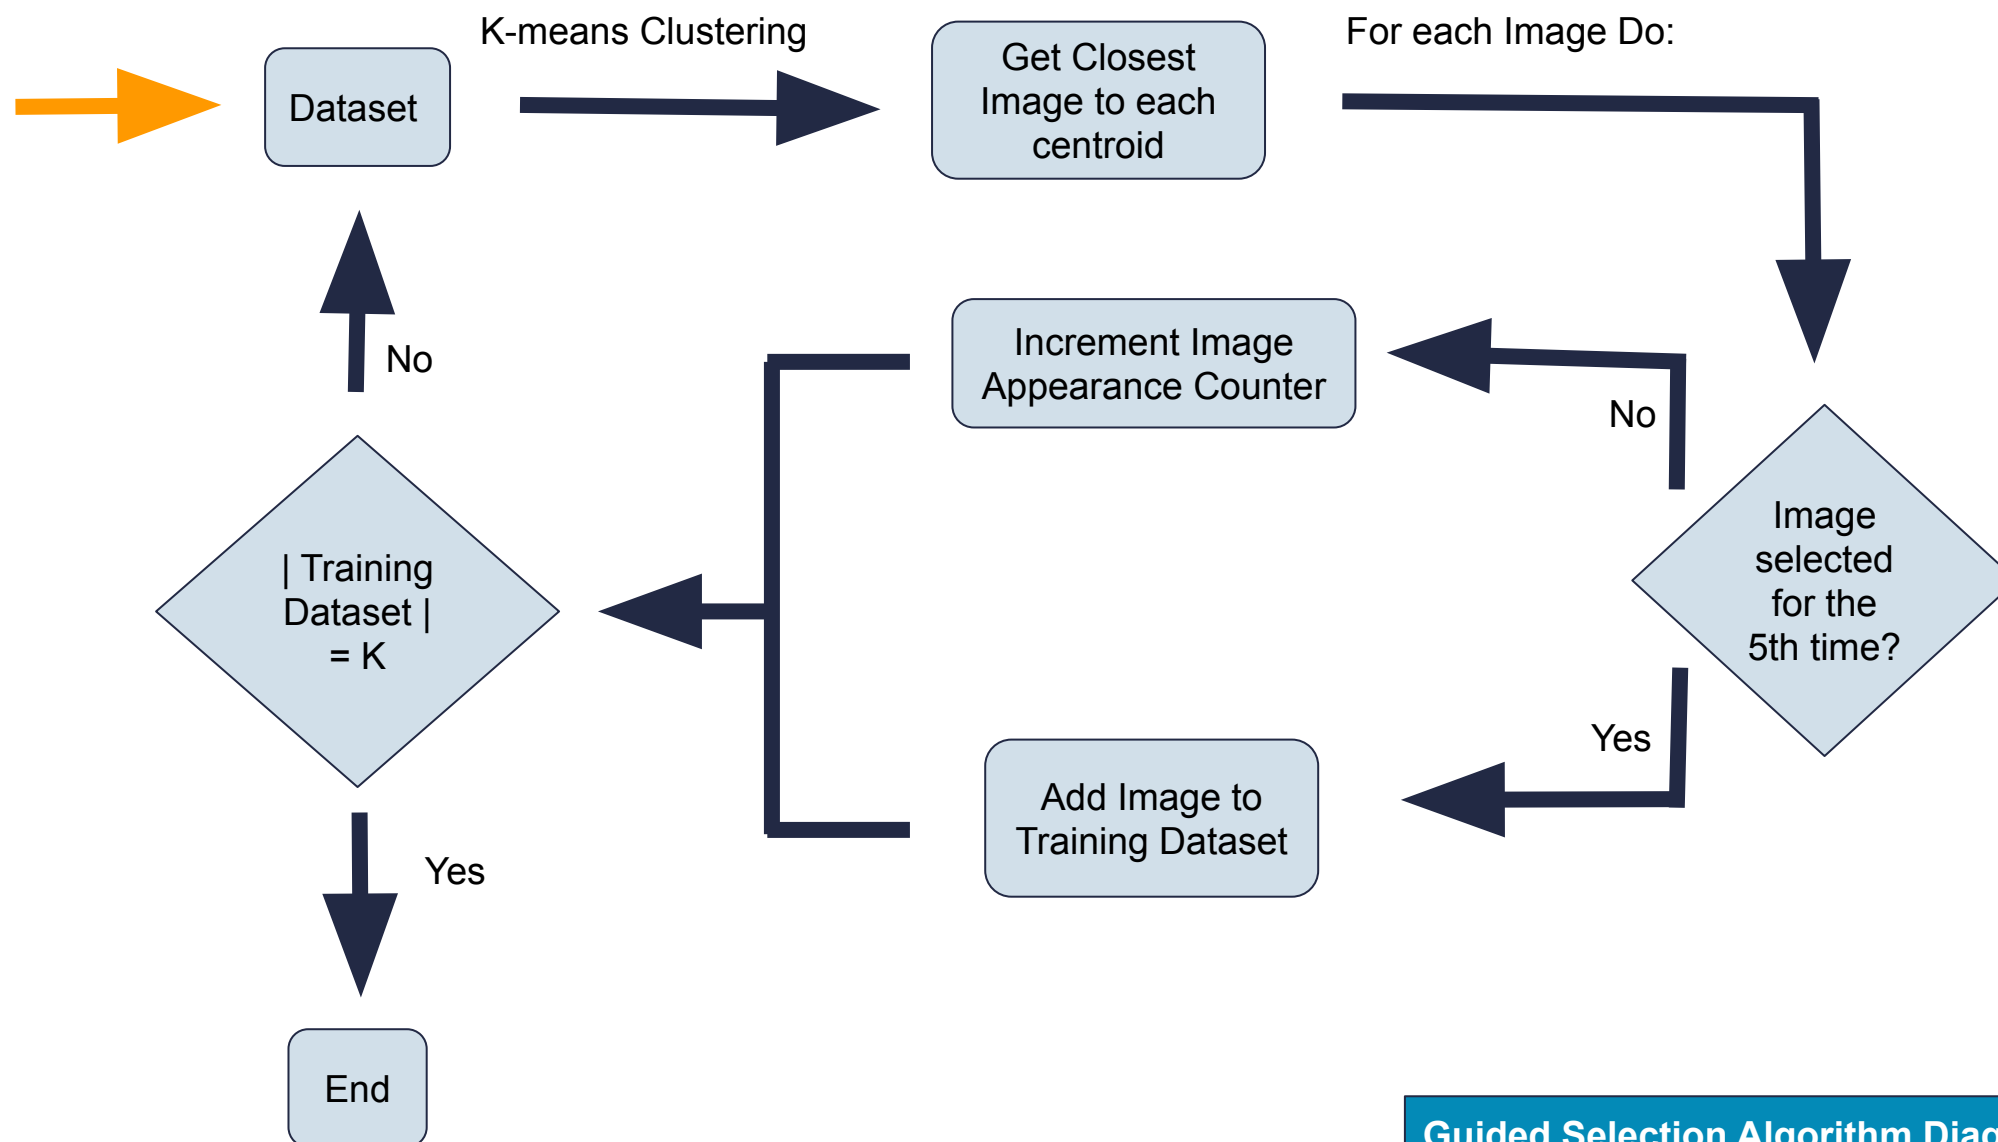
	Same Dataset	Diff Dataset
Custom Model	0.35	0.8
ResNet18	0.37	0.78

Accuracy Comparison

Guided Selection


- Com o intuito de minimizar o tamanho do dataset de treino, tentaram-se escolher as melhores imagens do dataset inicial, recorrendo a um método que usa o algoritmo de clustering K-means para selecionar as imagens que garantem a maior variabilidade possível.
- Compararam-se os desempenhos dos classificadores usando 50, 100, 200 e 300 imagens de treino selecionadas de forma aleatória e de forma guiada (através do K-means).

Guided Selection




Guided Selection Algorithm Diagram

Comparação da Accuracy



Custom Model Accuracy Comparison

Comparação da Accuracy



Conclusões e Trabalho Futuro

- É possível reduzir a dimensionalidade do problema devido à reprodutibilidade das métricas em todas as personagens.
- Observou-se que existe uma correlação entre a variabilidade das métricas do dataset e o desempenho do classificador.
- Utilizando uma seleção guiada das imagens para treino, conseguimos diminuir os recursos utilizados, mantendo o desempenho do classificador.
 - Custom Model: redução de 217 imagens por personagem
 - Resnet18: redução de 137 imagens por personagem
- Trabalho Futuro:
 - Comparar o desempenho de classificadores segundo um número de épocas variável.